

MACHINE LEARNING · CLASIFICACIÓN

Hotel Booking

Predicción de Cancelaciones

Clasificación supervisada · Random Forest optimizado · ROC-AUC 0.91

01 PROBLEMA DE NEGOCIO

37%

de reservas
se cancelan

2015-17

período analizado
(119.000 reservas)


€€€

impacto en ingresos
y ocupación

¿Cuál es el reto?

Las cancelaciones generan habitaciones vacías inesperadas, pérdida de ingresos y dificultad para planificar la ocupación. El hotel necesita anticiparse a estas cancelaciones para poder actuar: ajustar overbooking, revisar precios o aplicar políticas de cancelación diferenciadas.

02 PLANTEAMIENTO TÉCNICO



¿Por qué ML resuelve este problema? Disponemos de historial de reservas etiquetado (cancelada / no cancelada), múltiples variables predictoras y patrones repetibles que los algoritmos de clasificación supervisada pueden aprender para predecir futuros comportamientos.

03 DATASET & EDA

DATASET

Fuente:	Kaggle — Hotel Booking
Registros:	119.390 reservas
Periodo:	2015 - 2017
Variables:	36 → 18 tras limpieza
Target:	is_canceled (0 / 1)
Desbalance:	62% No / 38% Sí

HALLAZGOS CLAVE DEL EDA

-  Mayor lead_time → mayor probabilidad de cancelación (corr. 0.29)
-  Depósito no reembolsable: tasa de cancelación cercana al 100%
-  Reservas online (OTA): mayor inestabilidad que reservas directas
-  Clientes individuales (Transient) cancelan más que corporativos
-  Clientes repetidores tienen ~15% menos de cancelaciones

04 FEATURE ENGINEERING

TRANSFORMACIONES LOG

lead_time_log

`log1p(lead_time)` — reduce cola larga

adr_log

`log1p(adr)` — estabiliza precio/noche

previous_cancellations

`log1p(prev_canc)` — suaviza outliers

NUEVAS VARIABLES CREADAS

cancel_ratio

Ratio histórico de cancelaciones del cliente

had_previous_cancel

Binaria: ¿ha cancelado antes?

loyal_customer

Repetidor sin historial de cancelación

lead_time_x_adr

Interacción antelación × precio (top feature)

many_special_requests

≥2 peticiones especiales

needs_parking

Requiere plaza de aparcamiento

long_lead

Antelación > mediana del train

05 PIPELINE DE PREPROCESADO

Python — Pipeline

numeric_pipeline

```
= Pipeline([
    ("imputer", SimpleImputer(
        strategy="median")),
    ("scaler", StandardScaler())
])
```

categorical_pipeline

```
= Pipeline([
    ("imputer", SimpleImputer(
        strategy="most_frequent")),
    ("encoder", OneHotEncoder(
        handle_unknown="ignore"))
])
```

¿POR QUÉ UN PIPELINE?



Sin fuga de datos

Transformaciones ajustadas SOLO en train, aplicadas en test



Reproducible

Mismo flujo en entrenamiento, validación y producción



Numéricas

Mediana + StandardScaler → escala normalizada



Categorías

Moda + OneHotEncoder → sin valores desconocidos




Persistencia


joblib.dump guarda TODO el pipeline listo para inferencia

06 COMPARATIVA DE MODELOS

Balanced Accuracy



ROC-AUC



🏆 Ganador: Random Forest | Balanced Acc. 0.831 • ROC-AUC 0.920 → Seleccionado para optimización

07 OPTIMIZACIÓN & MODELO FINAL

CONFIGURACIÓN GRIDSEARCHCV	
CV:	StratifiedKFold · 5 folds
Scoring:	balanced_accuracy (refit)
n_estimators:	[200, 400]
max_depth:	[8, 12, 16]
min_samples_split:	[5, 10]
max_features:	["sqrt", "log2"]

MEJORES HIPERPARÁMETROS	
n_estimators:	400
max_depth:	16
min_samples_split:	5
min_samples_leaf:	2
max_features:	"sqrt"

COMPARATIVA FINAL — BASELINE VS MODELO OPTIMIZADO			
Modelo	Balanced Accuracy	ROC-AUC	F1 — Canceladas
Logistic Regression (baseline)	0.775	0.866	0.72
Random Forest optimizado ★	0.820	0.910	0.77

08 EVALUACIÓN CONTRA TEST

0.91

ROC-AUC

Excelente capacidad
discriminatoria

0.82

Balanced Accuracy

Equilibrio entre
ambas clases

0.77

F1 — Canceladas

Detección de la
clase objetivo

~80%

**Cancelaciones
anticipadas**

Verdaderos positivos
sobre total real

MATRIZ DE CONFUSIÓN (Resultados en test)

TN

13.227

Reservas NO canceladas
correctamente predichas

FP

1.806

Predicción: cancela
Realidad: no cancela

FN

2.182


Cancelaciones que
el modelo no anticipa

TP


6.663

Cancelaciones reales
correctamente detectadas


Curva ROC — Baseline vs Modelo Optimizado



Matriz de confusión — Modelo Optimizado



09 IMPORTANCIA DE VARIABLES



0.142



Las variables más influyentes son cat_deposit_type combinaciones de lead_time y adr.

10 CONCLUSIONES

Técnicas

Random Forest supera al baseline en todas las métricas (ROC-AUC +4.4%, Balanced Acc. +4.5%)

El Feature Engineering fue clave: las variables derivadas `lead_time_x_adr` y `cancel_ratio` figuran en el top 5 de importancia

El Pipeline garantiza ausencia total de fuga de información entre train y test

Balanced Accuracy como métrica principal evita sesgos hacia la clase mayoritaria

Negocio

El modelo anticipa ~80% de cancelaciones reales, reduciendo habitaciones vacías inesperadas

`Lead_time` y precio (ADR) son los drivers más accionables: alertas en el momento de reserva

Permite políticas diferenciadas: overbooking controlado, pricing dinámico según riesgo

Alta interpretabilidad: permite comunicar el riesgo de cancelación de forma clara al equipo de gestión

11 ACCIONES DE MEJORA

Corto plazo

Umbral de decisión personalizado

Ajustar el threshold de clasificación (actualmente 0.5) optimizando el trade-off entre falsos negativos y falsos positivos según el coste económico real de cada tipo de error para el hotel.

Largo plazo

Sistema de scores en tiempo real

Desplegar el modelo como API REST para calcular el riesgo de cancelación en el momento de la reserva, integrando el score en el sistema de gestión hotelera (PMS) para decisiones operativas automáticas.

Medio plazo

Incorporar variables temporales y de contexto

Añadir variables como la proximidad a festivales, estacionalidad mensual codificada de forma cíclica ($\sin/\cos$) y el precio relativo al mercado local para enriquecer el modelo con contexto externo.

Análisis adicional

Análisis de costes por segmento

Evaluar el impacto económico diferenciado por tipo de hotel (city vs resort), temporada y canal, para priorizar intervenciones donde el ROI de la predicción correcta sea mayor.

Gracias

0.91

ROC-AUC

0.82

Balanced Acc.

~80%

Cancelaciones
anticipadas

Brenda Oyola, Diana Hoyos, Elena Acosta · Machine Learning Project · Hotel Booking Demand · 2025